

RAPPORT DE PROJET

Business Intelligence / Data Engineering

Conception et Réalisation d'un Data Mart Décisionnel

Analyse de la Satisfaction Client dans un Contexte E- Commerce

Remerciements

Nous exprimons notre sincère gratitude à notre encadrant pédagogique pour son accompagnement, ses remarques constructives et son orientation tout au long de la réalisation de ce projet.

Nous remercions l'ensemble du corps enseignant pour la formation reçue en Business Intelligence, bases de données, modélisation dimensionnelle, ETL et visualisation décisionnelle.

Ce projet nous a permis de mobiliser plusieurs compétences complémentaires : compréhension métier, préparation de données, modélisation d'un Data Mart, orchestration ETL avec Talend, requêtage analytique dans PostgreSQL et conception d'un dashboard Power BI.

Résumé

Ce rapport présente la conception et la réalisation d'un Data Mart décisionnel dédié à l'analyse de la satisfaction client dans un contexte e-commerce. Le projet s'appuie sur le Brazilian ECommerce Public Dataset by Olist, qui regroupe des données relatives aux clients, commandes, produits, vendeurs, livraisons et avis clients.

L'objectif principal est de transformer des données transactionnelles brutes en un modèle décisionnel exploitable, capable de répondre à des questions métier liées à la satisfaction client : évolution temporelle des notes, impact des retards de livraison, performance des catégories de produits, analyse géographique et identification des vendeurs à faible satisfaction.

La solution repose sur une chaîne complète : chargement des fichiers CSV dans PostgreSQL, tables de staging, schéma étoile centré sur la table de faits F_AVIS, démonstration

d'historisation SCD Type 2 sur la dimension client, analyses OLAP en SQL et restitution dans un dashboard Power BI interactif.

Mots clés : Business Intelligence, Data Mart, Schéma étoile, Satisfaction client, Olist, PostgreSQL, Talend, Power BI, OLAP, SCD Type 2.

Abstract

This report presents the design and implementation of a decision-oriented Data Mart for customer satisfaction analysis in an e-commerce context. The project relies on the Brazilian E-Commerce Public Dataset by Olist, covering customers, orders, products, sellers, deliveries and customer reviews.

The solution includes CSV loading into PostgreSQL, staging tables, a star schema centered on the F_AVIS fact table, SCD Type 2 historization demonstration on the customer dimension, OLAP SQL analyses, and interactive KPI visualization through Power BI.

Keywords: Business Intelligence, Data Mart, Star Schema, Customer Satisfaction, Olist, PostgreSQL, Talend, Power BI, OLAP, SCD Type 2.

Glossaire

Terme	Définition
-------	------------

BI — Business Intelligence	Ensemble des méthodes et outils permettant de transformer des données brutes en informations utiles à la prise de décision.
Data Mart	Sous-ensemble thématique d'un Data Warehouse, dédié à un besoin analytique précis (ex. : satisfaction client).
Data Warehouse	Entrepôt de données centralisant les informations d'une organisation pour les analyses décisionnelles.
ETL — Extract, Transform, Load	Processus d'extraction, de transformation et de chargement des données depuis les sources vers la base décisionnelle.
OLAP — Online Analytical Processing	Analyse multidimensionnelle des données décisionnelles via drill-down, roll-up, slice et dice.
SCD Type 2	Slowly Changing Dimension Type 2 : méthode d'historisation conservant toutes les versions successives d'une dimension.
Schéma étoile	Modèle de données décisionnel composé d'une table de faits centrale reliée à plusieurs dimensions.
Table de faits	Table centrale contenant les mesures quantitatives à analyser (ex. : review_score, delivery_delay_days).
Dimension	Table descriptive permettant de filtrer, regrouper et analyser les faits selon un axe (temps, client, produit...).

Granularité	Niveau de détail retenu pour une ligne de la table de faits.
KPI — Key Performance Indicator	Indicateur clé de performance permettant de suivre l'activité ou la qualité d'un processus.
DAX — Data Analysis Expressions	Langage de calcul utilisé dans Power BI pour créer des mesures et colonnes calculées.
Staging	Zone intermédiaire contenant les données brutes avant transformation décisionnelle.
Surrogate Key	Clé primaire technique générée artificiellement, indépendante de la clé source.

Liste des figures et tableaux

Figures

Figure 1 Diagramme de Gantt	20
Figure 2 Structure relationnelle simplifiée du dataset Olist	25
Figure 3 Schéma étoile du Data Mart F_AVIS	32
Figure 4 Job Talend J04_SCD2_Demo	37
Figure 5 Requête de vérification SCD2	38
Figure 6 Flux global du processus ETL	40
Figure 7 Exemple de mapping Talend tMap : row1 → out_customers	43
Figure 8 Job J02_Load_Dimensions	44
Figure 9 Job J03_Load_F_AVIS	44
Figure 10 Requêtes de vérification du chargement	45
Figure 11 Vérification du Data Mart	46
Figure 12 KPI Globaux (Agrégation)	48
Figure 13 Répartition des scores (Agrégation)	48
Figure 14 Satisfaction par mois (Agrégation temporelle)	49
Figure 15 Satisfaction par catégorie produit	51
Figure 16 Roll-up : Catégorie → Total général	51

Figure 17 Satisfaction par région client (Agrégation géographique)	52
Figure 18 Slice : Impact du statut de livraison	53
Figure 19 Dice : Année × Région × Catégorie	53
Figure 20 Top vendeurs les moins bien notés	54
Figure 21 — Dashboard Power BI : Page 3 — Analyse géographique	61

Tableaux

- Tableau 1 — Planification du projet
- Tableau 2 — Technologies utilisées
- Tableau 3 — Fichiers CSV utilisés
- Tableau 4 — Jointures sources principales
- Tableau 5 — Mesures de la table de faits F_AVIS
- Tableau 6 — Structure de D_TEMPS
- Tableau 7 — Structure de D_CLIENT (SCD2)
- Tableau 8 — Structure de D_PRODUIT
- Tableau 9 — Structure de D_VENDEUR
- Tableau 10 — Structure de D_COMMANDE
- Tableau 11 — Structure complète de F_AVIS
- Tableau 12 — Colonnes SCD2 de D_CLIENT
- Tableau 13 — Jobs Talend créés
- Tableau 14 — Composants Talend utilisés

- Tableau 15 — Fichiers SQL livrés
- Tableau 16 — Récapitulatif des 10 analyses OLAP

- Tableau 17 — Relations Power BI
- Tableau 18 — Mesures DAX créées
- Tableau 19 — Récapitulatif des KPI et visualisations

Table des matières

Remerciements 2

Résumé 3

Abstract 4

Glossaire 5

Liste des figures et tableaux 7

 Figures 7

 Tableaux 8

Table des matières..... 10

Introduction générale 16

Chapitre 1 — Environnement du projet et contexte décisionnel 17

 1.1 Présentation du cadre du projet 17

 1.2 Problématique métier 17

 1.3 Processus métier retenu 17

 1.4 Questions business adressées 17

 1.5 Technologies utilisées 18

 1.6 Planification du projet..... 19

Chapitre 2 — Cahier des charges décisionnel	21
2.1 Besoins fonctionnels	21
2.2 Besoins non fonctionnels	21
2.3 Périmètre du projet	21
2.4 Livrables attendus	22
Chapitre 3 — Analyse des sources de données	24
3.1 Source principale : Brazilian E-Commerce Public Dataset (Olist)	24
3.2 Fichiers CSV utilisés	24
3.3 Structure relationnelle des données sources	25
3.4 Jointures sources principales	25
3.5 Observations qualité des données	26
Chapitre 4 — Conception du Data Mart décisionnel	27
4.1 Définition de la granularité	27
4.2 Identification des mesures	27
Formules SQL des mesures dérivées	28
4.3 Dimensions et hiérarchies	28

D_TEMPS — Dimension Temps	28
D_CLIENT — Dimension Client (SCD Type 2)	29
D_PRODUIIT — Dimension Produit	30
D_VENDEUR — Dimension Vendeur	30
D_COMMANDE — Dimension Commande	31
4.4 Schéma étoile — F_AVIS	31
Table de faits F_AVIS — Structure complète	32
Justification du schéma étoile	33
4.5 Convention de nommage	33
Chapitre 5 — Gestion de l'historisation — SCD Type 2	35
5.1 Principe retenu et limite du dataset	35
5.2 Dimension historisée et clé métier retenue	35
5.3 Colonnes SCD2 ajoutées à D_CLIENT	35
5.4 Logique d'implémentation	35
5.5 Démonstration — Job Talend J04_SCD2_Demo	36
5.6 Requête de vérification SCD2	37
5.7 Impact sur l'analyse décisionnelle	38
Chapitre 6 — Description du processus ETL	40
6.1 Architecture globale	40

6.2 Bases de données PostgreSQL	40
6.3 Jobs Talend — Chargement staging	41
6.4 Job J02_Load_Dimensions	43
6.5 Job J03_Load_F_AVIS	44
6.6 Fichiers SQL livrés	45
6.7 Requêtes de vérification du chargement	45
Vérification des tables staging	45
Vérification du Data Mart	45
Chapitre 7 — Analyses OLAP et requêtes décisionnelles	47
7.1 Opérations OLAP utilisées	47
7.2 Analyse 1 — KPI Globaux (Agrégation)	47
7.3 Analyse 2 — Répartition des scores (Agrégation)	48
7.4 Analyse 3 — Satisfaction par mois (Agrégation temporelle)	48
7.5 Analyse 4 — Drill-down : Année → Trimestre → Mois	49
7.6 Analyse 5 — Satisfaction par catégorie produit (Agrégation)	50
7.7 Analyse 6 — Roll-up : Catégorie → Total général	51

7.8 Analyse 7 — Satisfaction par région client (Agrégation géographique)	52
7.9 Analyse 8 — Slice : Impact du statut de livraison	52
7.10 Analyse 9 — Dice : Année × Région × Catégorie	53
7.11 Analyse 10 — Top vendeurs les moins bien notés.....	54
7.12 Récapitulatif des analyses OLAP	54
Chapitre 8 — Dashboard Power BI et indicateurs KPI	56
8.1 Connexion et modèle de données Power BI	56
Tables importées	56
Relations Power BI — Schéma étoile	56
8.2 Mesures DAX créées	56
Colonne calculée — Statut livraison (DAX)	57
8.3 Charte visuelle du dashboard	57
8.4 Page 1 — Vue globale satisfaction client	58
KPI affichés	58
Visualisations	58
Filtres interactifs	58
8.5 Page 2 — Analyse des produits et des vendeurs	59
Visualisations	59

Filtres interactifs	59
8.6 Page 3 — Analyse géographique	60
Visualisations	60
Filtres interactifs	60
8.7 Récapitulatif des KPI et visualisations	61
Chapitre 9 — Tests, validation et difficultés rencontrées	62
9.1 Tests réalisés	62
9.2 Difficultés rencontrées et solutions apportées	63
9.3 Améliorations possibles	64
Conclusion générale	65
Bibliographie et références	67
Références académiques	67
Sources de données	67
Documentation technique	67
Annexes	68
Annexe A — Organisation complète du dépôt projet	68

Annexe B — Guide d'insertion des captures 69

Introduction générale

Dans un environnement e-commerce, la satisfaction client constitue un indicateur stratégique. Elle permet d'évaluer la qualité perçue du service, la performance de la livraison, la pertinence des produits proposés et la fiabilité des vendeurs. Les avis clients représentent une source d'information précieuse, mais difficile à exploiter directement lorsqu'ils sont dispersés dans des fichiers transactionnels séparés.

Le présent projet a pour objectif de concevoir une solution décisionnelle capable de centraliser, transformer et analyser les données issues du dataset Olist. La démarche couvre toute la chaîne BI : compréhension des sources, modélisation dimensionnelle, processus ETL avec Talend, analyses OLAP en SQL, et restitution dans un dashboard Power BI interactif.

Ce projet consiste à concevoir un Data Mart décisionnel dédié à l'analyse de la satisfaction client dans un contexte e-commerce. À partir du dataset Olist, les données clients, commandes, produits, vendeurs et avis ont été intégrées dans une base PostgreSQL via un processus ETL réalisé avec Talend. Le modèle repose sur un schéma étoile centré sur la table de faits F_AVIS.

Le rapport est structuré en neuf chapitres. Les premiers chapitres présentent le contexte, le cahier des charges et l'analyse des sources. Les chapitres centraux détaillent la conception du Data Mart, l'ETL, les analyses OLAP et le dashboard Power BI. Les derniers chapitres abordent les tests réalisés, les difficultés rencontrées et les perspectives d'amélioration.

Chapitre 1 — Environnement du projet et contexte décisionnel

1.1 Présentation du cadre du projet

Ce projet a été réalisé dans le cadre d'un module de Business Intelligence et Data Engineering. Il vise à reproduire une situation proche d'un besoin réel d'entreprise : transformer des données opérationnelles issues d'une plateforme e-commerce en indicateurs décisionnels exploitables par des responsables métier.

1.2 Problématique métier

Dans une plateforme e-commerce, une note faible peut être liée à plusieurs facteurs : produit non conforme, retard de livraison, expérience d'achat décevante ou problème lié au vendeur. Une analyse isolée des avis ne suffit pas. Il faut croiser les avis avec les informations de commande, les produits, les vendeurs et les localisations.

Comment construire un système décisionnel permettant d'identifier les facteurs qui influencent la satisfaction client et de suivre ces facteurs dans le temps ?

1.3 Processus métier retenu

Le processus métier retenu est l'analyse de la satisfaction client à partir des avis déposés après achat. L'objectif est d'identifier les facteurs influençant les notes clients : produits, vendeurs, livraison, localisation géographique et évolution temporelle.

1.4 Questions business adressées

Question métier	Intérêt décisionnel
Quel est le niveau global de satisfaction client ?	Piloter la satisfaction globale
Comment la satisfaction évolue-t-elle dans le temps ?	Détecter les tendances et variations mensuelles
Quelles catégories sont les moins bien notées ?	Orienter les actions qualité / produit
Les retards de livraison influencent-ils les notes ?	Mesurer l'impact logistique sur l'expérience client
Quelles régions sont les plus insatisfaites ?	Identifier des zones géographiques à risque
Quels vendeurs sont associés aux avis faibles ?	Suivre et contrôler la qualité des vendeurs

Quelle est la répartition positif / négatif / neutre ?	Segmenter les avis pour des actions ciblées
--	---

1.5 Technologies utilisées

Outil	Version	Rôle dans le projet
PostgreSQL / pgAdmin	15+	Base de données décisionnelle, requêtes SQL, OLAP
Talend Open Studio	7.3.1	Orchestration du processus ETL
JDK	11 (LTS)	Requis pour Talend 7.3.1 (incompatible avec JDK 17)
Power BI Desktop — version récente — dashboard interactif, mesures DAX et KPI		
Olist Dataset	2018	Source principale des données e-commerce

1.6 Planification du projet

Phase	Durée estimée	Objectif
Phase 1 — Analyse du besoin	1 jour	Choix du processus métier et étude du dataset Olist

Phase 2 — Modélisation	2 jours	Définition de la granularité, des mesures, des dimensions et du schéma étoile
Phase 3 — Base PostgreSQL	2 jours	Création des tables staging, dimensions et table de faits
Phase 4 — ETL Talend	3 jours	Chargement des CSV, mapping, transformations et alimentation du Data Mart
Phase 5 — OLAP	2 jours	Écriture et validation des requêtes analytiques
Phase 6 — Power BI & rapport	3 jours	Création du dashboard, insertion des captures et finalisation du rapport




Figure 1 Diagramme de Gantt

Chapitre 2 — Cahier des charges décisionnel

2.1 Besoins fonctionnels

- Charger les fichiers CSV sources dans une base PostgreSQL via Talend.
- Construire des tables de staging pour conserver les données brutes.
- Créer les dimensions décisionnelles : D_TEMPS, D_CLIENT, D_PRODUIT, D_VENDEUR, D_COMMANDE.

- Créer la table de faits F_AVIS contenant les mesures liées aux avis clients.
- Gérer l'historisation de la dimension D_CLIENT selon une logique SCD Type 2.
- Réaliser au minimum 5 analyses OLAP en SQL (drill-down, roll-up, slice, dice).
- Restituer les KPI dans un dashboard Power BI interactif avec filtres dynamiques.

2.2 Besoins non fonctionnels

Critère	Exigence
Fiabilité	Les règles de calcul doivent éviter les erreurs de double comptage des avis (COUNT DISTINCT).
Traçabilité	Les données brutes doivent rester disponibles dans les tables staging après chargement.
Maintenabilité	Les scripts SQL, jobs Talend et fichiers Power BI doivent être organisés et nommés clairement.
Performance	Le schéma étoile doit minimiser les jointures et optimiser les requêtes analytiques.
Évolutivité	Le modèle doit pouvoir être enrichi avec de nouvelles sources ou dimensions à l'avenir.

2.3 Périmètre du projet

Le périmètre retenu est volontairement limité au dataset Olist, afin de livrer une chaîne BI complète et cohérente dans le cadre d'un module : chargement CSV, staging, Data Mart, ETL Talend, requêtes OLAP et dashboard Power BI. Les sources externes mentionnées dans l'énoncé ne sont pas intégrées dans cette version.

2.4 Livrables attendus

Livrable	Localisation dans le dépôt
Scripts SQL de création et chargement	sql/create_tables.sql, sql/load_data.sql
Requêtes OLAP documentées	sql/queries.sql
Script de démonstration SCD2	sql/scd2_demo.sql
Projet ETL Talend	etl/projet_talend/PROJET_BI_SATISFACTION/
Dashboard Power BI	powerbi/dashboard.pbix
Rapport de projet	rapport.pdf
Datasets sources	datasets/*.csv

Captures d'écran	captures/talend/, captures/postgresql/, captures/olap/, captures/powerbi/
------------------	---

2.5 Matrice rapide de conformité avec le cahier des charges

Cette matrice synthétise l'alignement du rapport avec les exigences principales de l'énoncé.

Exigence	Réponse dans le rapport	Statut
Processus métier choisi	Satisfaction client à partir des avis postachat	OK
Granularité de F_AVIS	1 item de commande avec avis client	OK
Mesures et indicateurs	Score, nombre d'avis, délai, commentaire, retard, avis positif/négatif	OK
Dimensions et hiérarchies	Temps, client, produit, vendeur, commande	OK
Schéma étoile	F_AVIS au centre, cinq dimensions autour	OK
ETL obligatoire	Talend + PostgreSQL + staging + chargement Data Mart	OK

SCD Type 2	D_CLIENT avec date_debut, date_fin, is_current	OK
Analyses OLAP	10 analyses avec drill-down, roll-up, slice, dice	OK+
Dashboard Power BI	5 KPI, 3 pages, filtres interactifs, plusieurs visuels	OK

Chapitre 3 — Analyse des sources de données

3.1 Source principale : Brazilian E-Commerce Public Dataset (Olist)

La source principale du projet est le dataset Olist, disponible sur Kaggle à l'adresse : <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Ce jeu de données au format CSV contient plusieurs tables décrivant toute l'activité d'une plateforme e-commerce brésilienne : clients, commandes, produits, vendeurs, paiements, livraisons et avis clients.

3.2 Fichiers CSV utilisés

Fichier source CSV	Table staging	Contenu
olist_customers_dataset.csv	stg_customers	Clients et localisation géographique
olist_orders_dataset.csv	stg_orders	Commandes, statuts, dates d'achat et de livraison
olist_order_reviews_dataset.csv	stg_reviews	Avis clients : score, titre, commentaire, dates

olist_order_items_dataset.csv	stg_order_items	Lignes de commande : produits, vendeurs, prix
olist_products_dataset.csv	stg_products	Caractéristiques produits (catégorie, dimensions, poids)
olist_sellers_dataset.csv	stg_sellers	Informations sur les vendeurs : ville, région
product_category_name_translation.csv	stg_category_translation	Traduction des catégories produits vers l'anglais

3.3 Structure relationnelle des données sources

Le modèle source est construit autour de la relation entre avis, commandes, clients, produits et vendeurs. Le schéma de relations se présente comme suit :

Figure 2 — Structure relationnelle simplifiée du dataset Olist




Figure 2 Structure relationnelle simplifiée du dataset Olist

3.4 Jointures sources principales

Relation	Clé de jointure
stg_reviews → stg_orders	order_id
stg_orders → stg_customers	customer_id
stg_orders → stg_order_items	order_id
stg_order_items → stg_products	product_id

stg_order_items → stg_sellers	seller_id
-------------------------------	-----------

3.5 Observations qualité des données

- Certains avis sont liés à des commandes contenant plusieurs produits (lignes order_items multiples) → gestion de la granularité.
- Certains champs de commentaires peuvent être nuls ou vides → géré par la mesure has_comment.
- Certaines commandes n'ont pas de date de livraison réelle → delivery_delay_days peut être NULL.
- Les catégories produits sont en portugais dans le fichier source → traduction via stg_category_translation.
- Certains produits n'ont pas de catégorie traduite → gérés avec la valeur 'Unknown Category'.

Point de périmètre — Les sources externes proposées dans l'énoncé n'ont pas été intégrées, afin de garder un Data Mart cohérent centré sur la satisfaction client. Elles sont uniquement citées comme pistes d'extension éventuelle.

Chapitre 4 — Conception du Data Mart décisionnel

4.1 Définition de la granularité

1 ligne de F_AVIS = 1 item de commande appartenant à une commande ayant reçu un avis client.

Dans le dataset Olist, un avis est associé à une commande via `order_id`. Or, une commande peut contenir plusieurs produits via la table `order_items`. Pour permettre l'analyse de la satisfaction par produit et par vendeur, l'avis est projeté au niveau de chaque ligne de commande (order item). Cette granularité est pertinente pour croiser la satisfaction avec les produits et les vendeurs, mais elle impose une règle importante : les indicateurs globaux doivent éviter le double comptage des avis répétés sur plusieurs items.

Point de vigilance — Un même avis peut être répété sur plusieurs lignes de `F_AVIS` lorsqu'une commande contient plusieurs items. Le nombre d'avis doit donc être calculé avec `COUNT(DISTINCT review_id)`. Pour les KPI globaux et la note moyenne décisionnelle, une agrégation préalable par `review_id` est préférable afin d'éviter la surpondération des commandes multi-items.

4.2 Identification des mesures

Mesure	Type	Description	Utilisation
review_score	Entier (1–5)	Score de satisfaction donné par le client	Note moyenne, répartition
review_count	Entier (1)	Compteur unitaire	Volume de lignes de faits

days_to_review	Entier	Délai entre achat et date de l'avis	Analyse du délai de réponse
comment_length	Entier	Longueur du commentaire en caractères	Analyse des commentaires
delivery_delay_days	Entier signé	Écart livraison réelle / estimée	Impact logistique
has_comment	Booléen 0/1	1 si commentaire présent	Comparaison avec/sans commentaire
is_positive_review	Booléen 0/1	1 si review_score $\geq$ 4	Taux d'avis positifs
is_negative_review	Booléen 0/1	1 si review_score $\leq$ 2	Taux d'avis négatifs

Formules SQL des mesures dérivées

```
days_to_review      = DATE(review_creation_date) - DATE(order_purchase_timestamp)
delivery_delay_days = DATE(order_delivered_customer_date) - DATE(order_estimated_delivery_date)
comment_length      = LENGTH(review_comment_message)
has_comment         = CASE WHEN
review_comment_message IS NULL
                      OR TRIM(review_comment_message) = ''
THEN 0 ELSE 1 END
is_positive_review  = CASE WHEN review_score >= 4 THEN 1 ELSE 0 END
is_negative_review  = CASE WHEN review_score <= 2 THEN 1 ELSE 0 END
```

4.3 Dimensions et hiérarchies

D_TEMPS — Dimension Temps

Attribut	Description
time_key	Clé primaire technique (entier)
date	Date complète (YYYY-MM-DD)
year	Année (ex. : 2018)
quarter	Trimestre (1 à 4)
month	Mois (1 à 12)
day	Jour du mois (1 à 31)
day_of_week	Jour de la semaine (Lundi...Dimanche)

Hiérarchie : Année → Trimestre → Mois → Jour

D_CLIENT — Dimension Client (SCD Type 2)

Attribut	Description
client_key	Clé primaire technique (surrogée)

customer_unique_id	Identifiant unique du client ; clé métier retenue pour le suivi SCD Type 2
customer_id	Identifiant client source lié à une commande
customer_city	Ville du client (historisé SCD2)
customer_state	Région du client (historisé SCD2)
date_debut	Date de début de validité de la version
date_fin	Date de fin de validité (NULL si version active)
is_current	TRUE si version active, FALSE sinon

Hiérarchie : Région → Ville → Client

D_PRODUIT — Dimension Produit

Attribut	Description
----------	-------------

produit_key	Clé primaire technique (surrogée)
product_id	Identifiant produit source
product_category_name	Catégorie produit en portugais
product_category_name_english	Catégorie traduite en anglais
product_weight_g	Poids en grammes
product_length_cm	Longueur en cm
product_height_cm	Hauteur en cm
product_width_cm	Largeur en cm

Hiérarchie : Catégorie produit → Produit

D_VENDEUR — Dimension Vendeur

Attribut	Description
vendeur_key	Clé primaire technique (surrogée)
seller_id	Identifiant vendeur source

seller_city	Ville du vendeur
seller_state	Région du vendeur

Hiérarchie : Région vendeur → Ville vendeur → Vendeur

D_COMMANDE — Dimension Commande

Attribut	Description
commande_key	Clé primaire technique (surrogée)
order_id	Identifiant commande source
order_status	Statut de la commande (delivered, shipped, cancelled...)
purchase_date	Date d'achat
delivered_date	Date de livraison réelle
estimated_delivery_date	Date de livraison estimée

4.4 Schéma étoile — F_AVIS

Le modèle décisionnel adopté est un schéma étoile, avec la table de faits F_AVIS au centre, entourée de cinq dimensions




Figure 3 Schéma étoile du Data Mart F_AVIS

Table de faits F_AVIS — Structure complète

Colonne	Type SQL	Rôle
avis_key	SERIAL	Clé primaire technique
time_key	INTEGER	Clé étrangère → D_TEMPS

client_key	INTEGER	Clé étrangère → D_CLIENT
produit_key	INTEGER	Clé étrangère → D_PRODUIT
vendeur_key	INTEGER	Clé étrangère → D_VENDEUR
commande_key	INTEGER	Clé étrangère → D_COMMANDE
review_id	VARCHAR	Identifiant source de l'avis
order_id	VARCHAR	Identifiant source de la commande
review_score	INTEGER	Score de satisfaction (1–5)
review_count	INTEGER	Compteur unitaire
days_to_review	INTEGER	Délai achat → avis (jours)
comment_length	INTEGER	Longueur du commentaire

delivery_delay_days	INTEGER	Retard (+) / avance (–) de livraison
has_comment	SMALLINT	1 si commentaire présent
is_positive_review	SMALLINT	1 si review_score $\geq$ 4
is_negative_review	SMALLINT	1 si review_score $\leq$ 2

Justification du schéma étoile

- F_AVIS concentre toutes les mesures quantitatives, les dimensions portent les attributs descriptifs.
- Ce modèle minimise les jointures et optimise les performances de requêtage OLAP.
- Power BI supporte nativement le schéma étoile et génère automatiquement les relations.
- La séparation faits/dimensions garantit l'évolutivité du modèle.

4.5 Convention de nommage

Préfixe	Type de table	Exemples
stg_	Tables staging (données brutes)	stg_customers, stg_reviews, stg_orders
d_	Dimensions décisionnelles	d_client, d_produit, d_temps, d_vendeur
f_	Table de faits	f_avis

Chapitre 5 — Gestion de l'historisation — SCD Type 2

5.1 Principe retenu et limite du dataset

La logique SCD Type 2 a été intégrée pour répondre à l'exigence d'historisation du projet. Dans le dataset Olist, les données sont statiques : elles ne contiennent pas naturellement un historique complet des changements de localisation client. La SCD2 est donc présentée comme une démonstration pédagogique contrôlée : on simule un changement de ville ou de région pour un client et on conserve l'ancienne version au lieu de l'écraser.

5.2 Dimension historisée et clé métier retenue

La dimension historisée est D_CLIENT. La clé métier suivie est customer_unique_id, car elle représente le même client à travers plusieurs commandes. L'attribut customer_id est conservé comme identifiant source lié à une commande, mais il ne constitue pas la meilleure clé pour suivre l'évolution historique d'un client.

- customer_city : ville du client
- customer_state : région / État du client

5.3 Colonnes SCD2 ajoutées à D_CLIENT

Colonne	Type SQL	Rôle
---------	----------	------

date_debut	DATE	Date de début de validité de cette version
date_fin	DATE / NULL	Date de fin de validité (NULL = version active)
is_current	BOOLEAN	TRUE si version courante, FALSE si historique

5.4 Logique d'implémentation

Lorsqu'un changement est détecté pour un `customer_unique_id`, l'ancienne ligne active de `D_CLIENT` n'est pas modifiée directement. Elle est clôturée, puis une nouvelle ligne est insérée avec les nouvelles valeurs. Cette méthode conserve les deux états du client : l'état historique et l'état courant.

1. Clôturer l'ancienne version : `date_fin = CURRENT_DATE` et `is_current = FALSE`.
2. Insérer la nouvelle version : `date_debut = CURRENT_DATE`, `date_fin = NULL` et `is_current = TRUE`.

-- Étape 1 : clôturer la version active du client

```
UPDATE d_client
SET   date_fin  = CURRENT_DATE,
      is_current = FALSE
WHERE customer_unique_id = '<uid_client>'
AND   is_current = TRUE;
```

-- Étape 2 : insérer la nouvelle version du client

```
INSERT INTO d_client
(customer_unique_id, customer_id, customer_city,
customer_state, date_debut, date_fin, is_current)
VALUES
('<uid_client>', '<id_client>', 'rio de janeiro', 'RJ',
```



```
CURRENT_DATE, NULL, TRUE);
```

5.5 Démonstration — Job Talend J04_SCD2_Demo

Le job Talend J04_SCD2_Demo sert à démontrer le mécanisme SCD2 sur D_CLIENT. Il sélectionne un client actif, clôture son ancienne version, puis insère une nouvelle version avec une localisation modifiée. Cette démonstration prouve la logique d'historisation, même si le dataset source ne fournit pas nativement un flux de changements successifs.




Figure 4 Job Talend J04_SCD2_Demo

5.6 Requête de vérification SCD2

SELECT

```
client_key,  
customer_unique_id,  
customer_id,  
customer_city,  
customer_state,  
date_debut,  
date_fin,  
is_current
```

```
FROM d_client  
WHERE customer_unique_id = (  
  SELECT customer_unique_id  
  FROM d_client  
  GROUP BY customer_unique_id
```

```

HAVING COUNT(*) > 1
LIMIT 1
)

```

```
ORDER BY customer_unique_id, date_debut, client_key;
```

Query Query History

```

1  SELECT
2      client_key,
3      customer_unique_id,
4      customer_id,
5      customer_city,
6      customer_state,
7      date_debut,
8      date_fin,
9      is_current
10 FROM d_client
11 WHERE customer_id = (
12     SELECT customer_id
13     FROM d_client
14     GROUP BY customer_id
15     HAVING COUNT(*) > 1
16     LIMIT 1
17 )
18 ORDER BY client_key;

```

Data Output Messages Notifications

Showing rows: 1 to 2 Page No: 1 of 1

	customer_unique_id character varying (50)	customer_id character varying (50)	customer_city character varying (100)	customer_state character varying (10)	date_debut date	date_fin date	is_current boolean
1	0000366f3b9a7992bf8c76cfd3221...	fadbb3709178fc513abc1b2670aa1a...	cajamar	SP	2026-05-03	2026-05-...	false
2	0000366f3b9a7992bf8c76cfd3221...	fadbb3709178fc513abc1b2670aa1a...	rio de janeiro	SP	2026-05-03	[null]	true

Figure 5 Requête de vérification SCD2

Résultat attendu : deux lignes pour le même customer_unique_id — l'ancienne version possède is_current = false et une date_fin renseignée ; la nouvelle version possède is_current = true et date_fin = NULL.

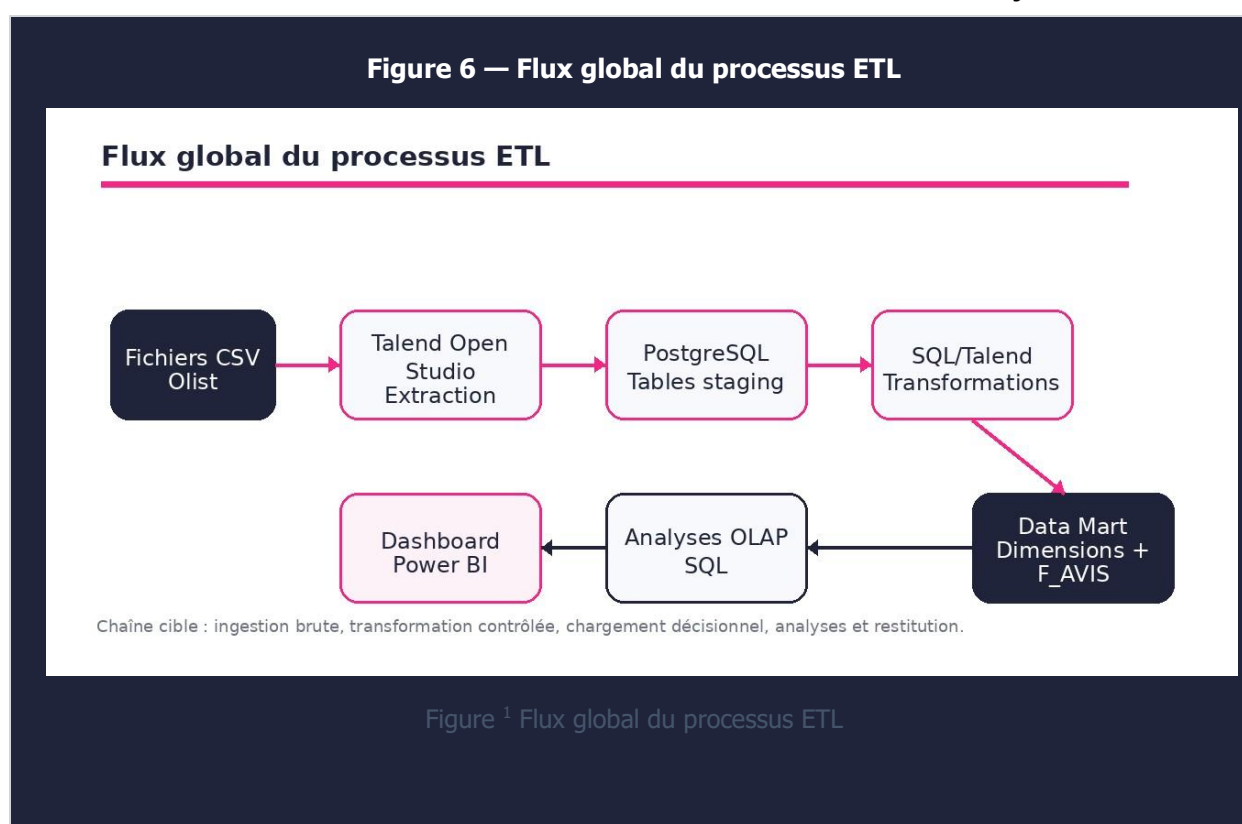
5.7 Impact sur l'analyse décisionnelle

La SCD2 garantit qu'une analyse historique peut distinguer l'ancienne localisation d'un client de sa localisation courante. Dans ce projet, les faits sont reliés à D_CLIENT par client_key ; il ne faut donc pas filtrer systématiquement sur is_current lors d'une analyse historique. Le filtre is_current = TRUE ne doit être utilisé que pour consulter l'état actuel des clients. La démonstration reste pédagogique, car le dataset Olist est statique, mais elle respecte le principe attendu d'une dimension lentement changeante de type 2.

Chapitre 6 — Description du processus ETL

6.1 Architecture globale

Le processus ETL a été réalisé en plusieurs étapes. Les fichiers CSV du dataset Olist sont d'abord extraits et chargés dans des tables staging PostgreSQL à l'aide de Talend. Les transformations décisionnelles sont ensuite appliquées via des requêtes SQL orchestrées par Talend, permettant de charger les dimensions et la table de faits. Cette organisation sépare clairement les données brutes des données décisionnelles et facilite la traçabilité.



¹ .2 Bases de données PostgreSQL

Base PostgreSQL	Rôle
projet_bi	Base initiale : prototype fonctionnel pour valider le modèle manuellement (CSV → staging → dimensions → F_AVIS → OLAP)
projet_bi_talend	Base finale : version ETL Talend complète, connectée à Power BI — à utiliser comme référence

6.3 Jobs Talend — Chargement staging

Job Talend	Table cible	Source CSV
J01_Load_Staging_Customers	stg_customers	olist_customers_dataset.csv
J01_Load_Staging_Orders	stg_orders	olist_orders_dataset.csv
J01_Load_Staging_Reviews	stg_reviews	olist_order_reviews_dataset.csv
J01_Load_Staging_Order_Items	stg_order_items	olist_order_items_dataset.csv
J01_Load_Staging_Products	stg_products	olist_products_dataset.csv
J01_Load_Staging_Sellers	stg_sellers	olist_sellers_dataset.csv

J01_Load_Staging_Category_Translation	stg_category_translation	product_category_name_translation.csv
---------------------------------------	--------------------------	---------------------------------------

Flux type de chaque job de staging :

tPostgresqlRow → tFileInputDelimited → tMap → tPostgresqlOutput

Composant Talend	Rôle
tPostgresqlRow	Vider (TRUNCATE) la table staging avant chargement
tFileInputDelimited	Lire le fichier CSV source
tMap	Mapper les colonnes source vers les colonnes cible et appliquer les conversions de types
tPostgresqlOutput	Insérer les données dans PostgreSQL




Figure 7 Jobs Talend — Chargement staging

L'exemple suivant montre le mapping réalisé dans tMap pour charger les données clients : chaque colonne source row1 est reliée à la colonne correspondante de la sortie out_customers.

Figure 8 Exemple de mapping Talend tMap : row1 → out_customers




Figure 7 Exemple de mapping Talend tMap : row1 → out_customers

6.4 Job J02_Load_Dimensions

Ce job orchestre le chargement de toutes les dimensions décisionnelles depuis les tables staging. Plusieurs composants tPostgresqlRow sont reliés en séquence avec OnSubjobOk.

Ordre d'exécution :

3. Vider F_AVIS et toutes les dimensions (TRUNCATE)
4. Charger D_CLIENT depuis stg_customers
5. Charger D_PRODUIT depuis stg_products
6. Traduire les catégories produit via stg_category_translation
7. Gérer les catégories non traduites ('Unknown Category')
8. Charger D_VENDEUR depuis stg_sellers
9. Charger D_COMMANDE depuis stg_orders
10. Charger D_TEMPS depuis les dates de stg_orders




Figure 8 Job J02_Load_Dimensions

6.5 Job J03_Load_F_AVIS

Ce job exécute une requête INSERT INTO f_avis SELECT ... qui joint les tables staging avec les dimensions pour calculer les clés étrangères et toutes les mesures métier (days_to_review, delivery_delay_days, comment_length, has_comment, is_positive_review, is_negative_review).




Figure 9 Job J03_Load_F_AVIS

6.6 Fichiers SQL livrés

Fichier SQL	Contenu
sql/create_tables.sql	Création de toutes les tables : staging, dimensions et F_AVIS
sql/load_data.sql	Chargement des dimensions et de F_AVIS depuis les tables staging

sql/queries.sql	10 requêtes OLAP et KPI analytiques documentées
sql/scd2_demo.sql	Script de démonstration SCD Type 2 sur D_CLIENT

6.7 Requêtes de vérification du chargement

Vérification des tables staging

```
SELECT 'stg_customers' AS table_name, COUNT(*) FROM stg_customers
UNION ALL SELECT 'stg_orders', COUNT(*) FROM stg_orders
UNION ALL SELECT 'stg_reviews', COUNT(*) FROM stg_reviews
UNION ALL SELECT 'stg_order_items', COUNT(*) FROM stg_order_items
UNION ALL SELECT 'stg_products', COUNT(*) FROM stg_products
UNION ALL SELECT 'stg_sellers', COUNT(*) FROM stg_sellers
UNION ALL SELECT 'stg_category_translation', COUNT(*)
FROM stg_category_translation;
```

```
Starting job J03_Load_F_AVIS at 15:55 04/05/2026.
[statistics] connecting to socket on port 3508
[statistics] connected
```

Figure 10 Requêtes de vérification du chargement

Vérification du Data Mart

```
SELECT 'D_CLIENT' AS table_name, COUNT(*) FROM d_client
UNION ALL SELECT 'D_PRODUIT', COUNT(*) FROM d_produit
UNION ALL SELECT 'D_VENDEUR', COUNT(*) FROM d_vendeur
UNION ALL SELECT 'D_COMMANDE', COUNT(*) FROM d_commande
```

```
UNION ALL SELECT 'D_TEMPS', COUNT(*) FROM d_temps
UNION ALL SELECT 'F_AVIS', COUNT(*) FROM f_avis;
```

```
9 SELECT 'stg_products', COUNT(*) FROM stg_products
10 UNION ALL
11 SELECT 'stg_sellers', COUNT(*) FROM stg_sellers
12 UNION ALL
13 SELECT 'stg_category_translation', COUNT(*) FROM stg_category_translation;
```

Data Output Messages Notifications

	table_name text	count bigint
1	stg_category_translati...	71
2	stg_sellers	3095
3	stg_products	32951
4	stg_customers	99441
5	stg_orders	99441
6	stg_reviews	99224
7	stg_order_items	112650
Total rows: 7. Query completed: 00:00:00.140. SQL		

Figure 11 Vérification du Data Mart

Chapitre 7 — Analyses OLAP et requêtes décisionnelles

7.1 Opérations OLAP utilisées

Opération	Description	Exemple concret
Drill-down	Navigation du niveau agrégé vers le niveau détaillé	Année → Trimestre → Mois
Roll-up	Remontée vers un niveau d'agrégation supérieur	Catégorie produit → Total général
Slice	Filtrage sur une valeur unique d'une dimension	Uniquement les commandes en retard
Dice	Filtrage multi-dimensionnel simultané	Année 2018 + Région SP + Catégorie Electronics

7.2 Analyse 1 — KPI Globaux (Agrégation)

Pour les KPI globaux, les calculs sont réalisés sur les avis uniques afin d'éviter la surpondération des commandes contenant plusieurs items.

```
WITH avis_uniques AS (
SELECT
    review_id,
    MAX(review_score) AS review_score,
    MAX(delivery_delay_days) AS delivery_delay_days,
    MAX(is_positive_review) AS is_positive_review,
    MAX(is_negative_review) AS is_negative_review
```

The screenshot shows the Talend Data Studio interface. The top bar indicates the connection to 'projet_bi_talend/postgres@PostgreSQL 18'. The left sidebar shows a tree view of the database schema, including 'public', 'Aggreg', 'Collatic', 'Domain', 'FTS Co', 'FTS Dic', 'FTS Pa', 'FTS Te', 'Foreign', and 'Function'. The main area displays a SQL query in the 'Query' tab, and the 'Data Output' tab shows the results of the query.

Query:

```
1 SELECT
2     COUNT(*) AS nb_lignes_faits,
3     COUNT(DISTINCT review_id) AS nb_avis_distincts,
4     ROUND(AVG(review_score), 2) AS note_moyenne,
5     ROUND(100.0 * SUM(is_positive_review) / COUNT(*), 2) AS taux_avis_positifs,
6     ROUND(100.0 * SUM(is_negative_review) / COUNT(*), 2) AS taux_avis_negatifs,
7     ROUND(AVG(delivery_delay_days), 2) AS retard_moyen_livraison
8 FROM f_avis;
```

Data Output:

	nb_lignes_faits bigint	nb_avis_distincts bigint	note_moyenne numeric	taux_avis_positifs numeric	taux_avis_negatifs numeric	retard_moyen_livraison numeric
1	224744	97709	4.03	75.50	16.12	-12.07

Figure 12 KPI Globaux (Agrégation)

7.3 Analyse 2 — Répartition des scores (Agrégation)

```
SELECT
    review_score,
    COUNT(DISTINCT review_id) AS nb_avis,
    ROUND(
        COUNT(DISTINCT review_id) * 100.0
        / SUM(COUNT(DISTINCT review_id)) OVER (),
        2) AS pct
FROM f_avis
GROUP BY review_score
ORDER BY review_score;
```

Data Output				Messages	Notifications
	review_score integer	nb_lignes bigint	nb_avis_distincts bigint		
1	1	28470	10766		
2	2	7748	3059		
3	3	18846	8052		
4	4	42630	18978		
5	5	127050	56854		

Figure 13 Répartition des scores (Agrégation)

7.4 Analyse 3 — Satisfaction par mois (Agrégation temporelle)

```

SELECT
    t.year,
    t.month,
    COUNT(DISTINCT f.review_id) AS nb_avis,
    ROUND(AVG(f.review_score), 2) AS note_moyenne
FROM f_avis f
JOIN d_temps t ON f.time_key = t.time_key
GROUP BY t.year, t.month
ORDER BY t.year, t.month;

```

	year integer	month integer	note_moyenne numeric	nombre_avis bigint
1	2016	9	1.00	3
2	2016	10	3.61	302
3	2016	12	5.00	1
4	2017	1	4.07	768
5	2017	2	4.05	1715
6	2017	3	4.06	2611
7	2017	4	4.00	2363
8	2017	5	4.14	3616
9	2017	6	4.13	3181
10	2017	7	4.14	3921

Figure 14 Satisfaction par mois (Agrégation temporelle)

7.5 Analyse 4 — Drill-down : Année → Trimestre → Mois

```

SELECT
    t.year,
    t.quarter,
    t.month,
    COUNT(DISTINCT f.review_id) AS nb_avis,
    ROUND(AVG(f.review_score), 2) AS note_moyenne
FROM f_avis f
JOIN d_temps t ON f.time_key = t.time_key
GROUP BY
    GROUPING SETS (
        (t.year),

```



```

        (t.year, t.quarter),
        (t.year, t.quarter, t.month)
    )

```

```
ORDER BY t.year NULLS LAST, t.quarter NULLS LAST, t.month NULLS LAST;
```

Data Output Messages Notifications						
Showing rows: 1 to 8						
	year integer	quarter integer	month integer	note_moyenne numeric	nombre_avis bigint	
1	2016	3	9	1.00	3	
2	2016	4	10	3.61	302	
3	2016	4	12	5.00	1	
4	2017	1	1	4.07	768	
5	2017	1	2	4.05	1715	
6	2017	1	3	4.06	2611	
7	2017	2	4	4.00	2363	
8	2017	2	5	4.14	2616	
Total rows: 24 Query complete 00:00:02.621						

Figure 16 — Drill-down : Année → Trimestre → Mois

7.6 Analyse 5 — Satisfaction par catégorie produit (Agrégation)

```

SELECT
    p.product_category_name_english AS categorie,
    COUNT(DISTINCT f.review_id) AS nb_avis,
    ROUND(AVG(f.review_score), 2) AS note_moyenne
FROM f_avis f
JOIN d_produit p ON f.produit_key = p.produit_key
GROUP BY p.product_category_name_english
ORDER BY note_moyenne DESC;

```

Data Output Messages Notifications

	categorie_produit character varying (100)	note_moyenne numeric	nombre_avis bigint
1	diapers_and_hygiene	3.26	27
2	office_furniture	3.49	1265
3	home_comfort_2	3.63	23
4	fashion_male_clothing	3.64	111
5	fixed_telephony	3.68	215
6	party_supplies	3.77	39
7	fashio_female_clothing	3.78	41
8	furniture_mattress_and_upholstery	3.82	38
9	audio	3.83	348
10	home_comfort	3.83	308

Figure 15 Satisfaction par catégorie produit

7.7 Analyse 6 — Roll-up : Catégorie → Total général

```
SELECT
```

```
    COALESCE(p.product_category_name_english, '** TOTAL **') AS categorie,
```

```
    COUNT(DISTINCT f.review_id) AS nb_avis,
    ROUND(AVG(f.review_score), 2) AS note_moyenne
```

```
FROM f_avis f
```

```
JOIN d_produit p ON f.produit_key = p.produit_key
```

```
GROUP BY ROLLUP(p.product_category_name_english)
```

```
ORDER BY categorie NULLS LAST;
```

	categorie_produit	note_moyenne	nombre_avis
	character varying	numeric	bigint
1	agro_industry_and_commerce	4.00	182
2	air_conditioning	3.97	249
3	art	3.94	200
4	arts_and_craftmanship	4.13	23
5	audio	3.83	348
6	auto	4.07	3879
7	baby	4.01	2864
8	bed_bath_table	3.90	9324
9	books_general_interest	4.45	508

Figure 16 Roll-up : Catégorie → Total général

7.8 Analyse 7 — Satisfaction par région client (Agrégation géographique)

```
SELECT
```

```
    c.customer_state AS region,
```

```
    COUNT(DISTINCT f.review_id) AS nb_avis,
    ROUND(AVG(f.review_score), 2) AS note_moyenne
```

```
FROM f_avis f
```

```
JOIN d_client c ON f.client_key = c.client_key
```

```
GROUP BY c.customer_state
```

```
ORDER BY note_moyenne ASC;
```

Data Output Messages Notifications			
Showing rows			
	region_client character varying (10)	note_moyenne numeric	nombre_avis bigint
1	RR	3.58	46
2	MA	3.71	731
3	AL	3.72	409
4	PA	3.79	952
5	BA	3.81	3312
6	CE	3.81	1316
7	RJ	3.81	12564
8	SE	3.84	342
9	PI	3.90	487
10	PE	3.96	1632

Figure 17 Satisfaction par région client (Agrégation géographique)

7.9 Analyse 8 — Slice : Impact du statut de livraison

```

SELECT
  CASE
    WHEN delivery_delay_days > 0 THEN 'Livraison en retard'
    WHEN delivery_delay_days = 0 THEN 'Livraison à temps'
    WHEN delivery_delay_days < 0 THEN 'Livraison en avance'
    ELSE 'Date inconnue'
  END
  AS statut_livraison,
  COUNT(DISTINCT review_id) AS nb_avis,
  ROUND(AVG(review_score), 2) AS note_moyenne
FROM f_avis
GROUP BY statut_livraison
ORDER BY note_moyenne DESC;

```

	statut_livraison	note_moyenne	nombre_avis
	text	numeric	bigint
1	Date livraison inconn...	1.76	2102
2	Livraison en retard	2.26	6390
3	Livraison à temps	3.98	1289
4	Livraison en avance	4.21	88035

Figure 18 Slice : Impact du statut de livraison

7.10 Analyse 9 — Dice : Année × Région × Catégorie

SELECT

```
t.year,
c.customer_state AS region,
p.product_category_name_english AS categorie,
```

```
COUNT(DISTINCT f.review_id) AS nb_avis,
ROUND(AVG(f.review_score), 2) AS note_moyenne
```

FROM f_avis f

JOIN d_temps t ON f.time_key = t.time_key

JOIN d_client c ON f.client_key = c.client_key

JOIN d_produit p ON f.produit_key = p.produit_key

GROUP BY t.year, c.customer_state, p.product_category_name_english

ORDER BY t.year, note_moyenne ASC;

	annee integer	region character varying (10)	categorie character varying (100)	nb_avis bigint	note_moyenne numeric
1	2016	SP	books_technical	1	1.00
2	2016	RS	auto	1	1.00
3	2016	SC	fashion_bags_accessories	1	1.00
4	2016	RS	telephony	2	1.00
5	2016	RS	health_beauty	1	1.00
6	2016	RS	fashion_bags_accessories	1	1.00
7	2016	AL	computers_accessories	1	1.00
8	2016	PE	computers_accessories	1	1.00
9	2016	BA	watches_gifts	1	1.00
10	2016	MT	auto	1	1.00
11	2016	MG	sports_leisure	1	1.00

Figure 19 Dice : Année × Région × Catégorie

7.11 Analyse 10 — Top vendeurs les moins bien notés

SELECT

```
v.seller_id,
v.seller_city,
v.seller_state,
```

```
COUNT(DISTINCT f.review_id) AS nb_avis,
ROUND(AVG(f.review_score), 2) AS note_moyenne
```

```
FROM f_avis f
JOIN d_vendeur v ON f.vendeur_key = v.vendeur_key
GROUP BY v.seller_id, v.seller_city, v.seller_state
HAVING COUNT(DISTINCT f.review_id) >= 10
ORDER BY note_moyenne ASC
LIMIT 10;
```

	seller_id character varying (50)	seller_city character varying (100)	seller_state character varying (10)	note_moyenne numeric	nombre_avis bigint
1	4342d4b2ba6b161468c63a7e7cfce...	rio de janeiro	RJ	1.26	19
2	b1b3948701c5c72445495bd161b8...	sao paulo	SP	1.72	18
3	ffff564a4f9085cd26170f4732393726	campinas	SP	2.10	20
4	1ca7077d890b907f89be8c954a026...	santana de parnaiba	SP	2.20	114
5	973f21788dfab357250f69a8dcb7d...	claudio	MG	2.33	10
6	ecccf2bb93b34a3bf033cc5d1dcdc...	curitiba	PR	2.33	14
7	5bc55dbe2f12b6af6d83ed46023e0...	coronel fabriciano	MG	2.33	17
8	fa74b2f3287d296e9fbd2cc80f2d1c...	presidente prudente	SP	2.36	11
9	40db9e9aa57f7bb151bcda6b0f9bd...	recife	PE	2.36	11
10	b5abf4f36adc043117b4fca82c2298...	brasilia	DF	2.42	11

Figure 20 Top vendeurs les moins bien notés

7.12 Récapitulatif des analyses OLAP

N°	Analyse	Dimensions	Opération
1	KPI globaux	F_AVIS	Agrégation
2	Répartition des scores	F_AVIS	Agrégation
3	Satisfaction par mois	D_TEMPS	Agrégation temporelle

4	Drill-down Année → Trimestre → Mois	D_TEMPS	Drill-down
5	Satisfaction par catégorie produit	D_PRODUIT	Agrégation
6	Roll-up catégorie → total général	D_PRODUIT	Roll-up
7	Satisfaction par région client	D_CLIENT	Agrégation géographique
8	Impact statut de livraison	F_AVIS	Slice
9	Dice Année × Région × Catégorie	D_TEMPS + D_CLIENT + D_PRODUIT	Dice
10	Top vendeurs les moins bien notés	D_VENDEUR	Agrégation

Chapitre 8 — Dashboard Power BI et indicateurs KPI

8.1 Connexion et modèle de données Power BI

Le dashboard Power BI exploite directement le Data Mart chargé dans PostgreSQL (base projet_bi_talend). Il repose sur la table de faits F_AVIS et les cinq dimensions associées. Le rapport est structuré en trois pages thématiques avec filtres interactifs.

Tables importées

- public f_avis
- public d_temps
- public d_client
- public d_produit
- public d_vendeur
- public d_commande

Relations Power BI — Schéma étoile

Relation	Cardinalité
f_avis[time_key] → d_temps[time_key]	Plusieurs à un (Many-to-One)
f_avis[client_key] → d_client[client_key]	Plusieurs à un (Many-to-One)
f_avis[produit_key] → d_produit[produit_key]	Plusieurs à un (Many-to-One)
f_avis[vendeur_key] → d_vendeur[vendeur_key]	Plusieurs à un (Many-to-One)

f_avis[commande_key] → d_commande[commande_key]	Plusieurs à un (Many-to-One)
--	------------------------------

8.2 Mesures DAX créées

Mesure DAX	Formule complète
Note moyenne	ROUND(AVERAGEX(SUMMARIZE('public f_avis', 'public f_avis'[review_id], "ScoreAvis", MAX('public f_avis'[review_score])), [ScoreAvis]), 2)
Nombre avis	DISTINCTCOUNT('public f_avis'[review_id])
Taux avis positifs	ROUND(DIVIDE(CALCULATE(DISTINCTCOUNT('public f_avis'[review_id]), 'public f_avis'[is_positive_review] = 1), DISTINCTCOUNT('public f_avis'[review_id])) * 100, 2)
Taux avis négatifs	ROUND(DIVIDE(CALCULATE(DISTINCTCOUNT('public f_avis'[review_id]), 'public f_avis'[is_negative_review] = 1), DISTINCTCOUNT('public f_avis'[review_id])) * 100, 2)
Retard moyen livraison	ROUND(AVERAGEX(SUMMARIZE('public f_avis', 'public f_avis'[review_id], "RetardAvis", MAX('public f_avis'[delivery_delay_days])), [RetardAvis]), 2)

Colonne calculée — Statut livraison (DAX)

```
Statut livraison =  
  
SWITCH(  
    TRUE(),  
    ISBLANK('public f_avis'[delivery_delay_days]), "Date inconnue",  
    'public f_avis'[delivery_delay_days] > 0, "Livraison en retard",  
    'public f_avis'[delivery_delay_days] = 0, "Livraison à temps",  
    'public f_avis'[delivery_delay_days] < 0, "Livraison en avance"  
)
```

8.3 Charte visuelle du dashboard

Élément	Valeur
Fond dashboard	Bleu nuit #20243A
Couleur principale (KPI, entêtes)	Rose #F72585
Texte principal	Blanc
Texte secondaire	Gris clair
Style général	Sombre, aligné, style exécutif moderne

8.4 Page 1 — Vue globale satisfaction client

Titre : « Satisfaction Client Dashboard »

Sous-titre : « Analyse des avis clients, de la livraison, des produits et des régions »

KPI affichés

- Note moyenne — moyenne distincte par review_id
- Nombre d'avis — DISTINCTCOUNT(review_id)
- Taux avis positifs (%)
- Taux avis négatifs (%)
- Retard moyen de livraison (jours)

Visualisations

- Graphique temporel : évolution mensuelle de la note moyenne (courbe de tendance)
- Histogramme : répartition des scores 1 à 5
- Graphique en barres : impact du statut de livraison sur la satisfaction

Filtres interactifs

- Année (D_TEMPS)
- Région client (D_CLIENT)
- Catégorie produit (D_PRODUIT)




Figure 23 — Dashboard Power BI : Page 1 — Vue globale

8.5 Page 2 — Analyse des produits et des vendeurs

Titre : « Analyse des produits et des vendeurs »

Sous-titre : « Identification des catégories et vendeurs à faible satisfaction »

Visualisations

- Barres horizontales : satisfaction moyenne par catégorie produit (product_category_name_english)

- Colonnes : volume d'avis par catégorie produit
- Tableau analytique : « Vendeurs à surveiller » — colonnes seller_id, seller_city, seller_state, Note moyenne, Nombre avis — trié par note moyenne croissante, mise en forme conditionnelle

Filtres interactifs

- Année
- Région client




Figure 24 — Dashboard Power BI : Page 2 — Produits & Vendeurs

8.6 Page 3 — Analyse géographique

Titre : « Analyse géographique »

Sous-titre : « Analyse de la satisfaction client selon la localisation et le statut de livraison »

Visualisations

- Barres : satisfaction moyenne par région client (customer_state)
- Colonnes : volume d'avis par région client
- Matrice : satisfaction par région (lignes) × statut de livraison (colonnes) — valeurs : Note moyenne

Filtres interactifs

- Année
- Catégorie produit



Figure 21 — Dashboard Power BI : Page 3 — Analyse géographique

8.7 Récapitulatif des KPI et visualisations

KPI / Visualisation	Page	Type de visuel
Note moyenne	Page 1	Indicateur KPI
Nombre d'avis	Page 1	Indicateur KPI
Taux avis positifs (%)	Page 1	Indicateur KPI
Taux avis négatifs (%)	Page 1	Indicateur KPI
Retard moyen livraison	Page 1	Indicateur KPI
Évolution mensuelle satisfaction	Page 1	Graphique temporel (courbe)
Répartition des scores 1–5	Page 1	Histogramme
Impact statut livraison	Page 1	Barres
Satisfaction par catégorie produit	Page 2	Barres horizontales
Volume avis par catégorie	Page 2	Colonnes

Tableau Vendeurs à surveiller	Page 2	Tableau analytique
Satisfaction par région	Page 3	Barres
Volume avis par région	Page 3	Colonnes
Matrice région × statut livraison	Page 3	Matrice

Chapitre 9 — Tests, validation et difficultés rencontrées

9.1 Tests réalisés

Test	Méthode	Résultat attendu
Chargement des tables staging	COUNT(*) sur chaque stg_*	Volumes cohérents avec les CSV sources
Intégrité des dimensions	COUNT(*) sur d_client, d_produit, d_vendeur, d_commande, d_temps	Pas de doublons, clés uniques

Qualité de F_AVIS	COUNT(*) vs COUNT(DISTINCT review_id)	Ratio normal (> 1 si commandes multiitems)
Cohérence des clés étrangères	Jointures F_AVIS ↔ dimensions	0 ligne orpheline
Validation SCD2	Requête de vérification historisation	Deux lignes pour le client modifié
Résultats OLAP	Exécution des 10 requêtes	Résultats plausibles, note moyenne attendue ~4.0
Dashboard Power BI	Vérification des KPI vs requêtes SQL	Cohérence entre SQL et DAX

9.2 Difficultés rencontrées et solutions apportées

Difficulté	Solution
Talend 7.3.1 incompatible avec JDK 17	Installation et configuration d'un JDK 11 LTS

Double comptage des avis en raison de la granularité multi-items	Utilisation de COUNT(DISTINCT review_id) pour les volumes et calcul de la note moyenne sur les avis uniques lorsque l'indicateur est global.
Catégories produits sans traduction disponible	Assignment de la valeur 'Unknown Category' par défaut
Commandes sans date de livraison réelle	delivery_delay_days laissé à NULL, géré dans Power BI ('Date inconnue')
Clé étrangère orpheline lors du chargement F_AVIS	Ordre de chargement respecté : dimensions avant F_AVIS

9.3 Améliorations possibles

- Ajouter une dimension géographique dédiée si les coordonnées des villes sont disponibles.
- Automatiser l'exécution du flux ETL pour faciliter les mises à jour.
- Généraliser la SCD Type 2 avec un composant dédié ou une procédure SQL automatisée.
- Ajouter une analyse détaillée des délais de livraison par région et catégorie.

Conclusion générale

Ce projet a permis de construire un Data Mart décisionnel complet dédié à l'analyse de la satisfaction client dans un contexte e-commerce. À partir du dataset Olist, les données ont été intégrées dans PostgreSQL via un processus ETL réalisé avec Talend Open Studio 7.3.1.

La modélisation dimensionnelle adoptée respecte un schéma étoile structuré autour de la table de faits F_AVIS, entourée de cinq dimensions : D_TEMPS, D_CLIENT, D_PRODUIT, D_VENDEUR et D_COMMANDE. Ce modèle permet une analyse multidimensionnelle fine de la satisfaction client en croisant les avis avec les axes temporel, géographique, produit, vendeur et livraison.

La gestion de l'historisation SCD Type 2 a été démontrée sur la dimension D_CLIENT. Le job Talend J04_SCD2_Demo illustre le versionnement d'un client lorsque sa localisation change : l'ancienne version est clôturée et une nouvelle version active est insérée. Cette démonstration répond à l'exigence pédagogique du projet tout en tenant compte du caractère statique du dataset Olist.

Dix analyses OLAP ont été réalisées en SQL, exploitant les opérations de drill-down, roll-up, slice et dice. Ces analyses permettent d'identifier les facteurs de satisfaction et d'insatisfaction

: catégories de produits, régions à faible satisfaction, impact des retards de livraison et vendeurs à surveiller.

Le dashboard Power BI, structuré en trois pages thématiques, offre une restitution interactive et décisionnelle des résultats. Cinq KPI principaux, neuf visualisations complémentaires et plusieurs filtres interactifs permettent aux décideurs d'explorer dynamiquement la satisfaction client selon tous les axes du Data Mart.

Ce projet constitue une application concrète des concepts fondamentaux du Business Intelligence : modélisation dimensionnelle, processus ETL, historisation SCD2, analyses OLAP et restitution décisionnelle dans un outil de visualisation professionnel.

Bibliographie et références

Références académiques

- Kimball, R. & Ross, M. (2013). The Data Warehouse Toolkit — 3rd Edition. Wiley.
- Inmon, W.H. (2005). Building the Data Warehouse. Wiley.

Sources de données

- Brazilian E-Commerce Public Dataset by Olist — <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

Documentation technique

- PostgreSQL Documentation — <https://www.postgresql.org/docs/>
- Talend Open Studio Documentation — <https://www.talend.com>
- Microsoft Power BI Documentation — <https://learn.microsoft.com/power-bi>
- DAX Reference — <https://learn.microsoft.com/dax>

Annexes

Annexe A — Organisation complète du dépôt projet

```
Projet_BI/
|
├─ rapport.pdf
|
├─ sql/
|   ├─ create_tables.sql
|   ├─ load_data.sql
|   ├─ queries.sql
|   └─ scd2_demo.sql
|
├─ etl/
|   └─ projet_talend/
|       └─ PROJET_BI_SATISFACTION/
|
├─ powerbi/
|   └─ dashboard.pbix
|
├─ datasets/
|   ├─ olist_customers_dataset.csv
|   ├─ olist_orders_dataset.csv
|   ├─ olist_order_reviews_dataset.csv
|   ├─ olist_order_items_dataset.csv
|   ├─ olist_products_dataset.csv
|   ├─ olist_sellers_dataset.csv
|   └─ product_category_name_translation.csv
|
└─ captures/
    ├─ talend/
    ├─ postgresql/
    ├─ olap/
    └─ powerbi/
```


Annexe B — Guide d'insertion des captures

Capture	Dossier	Section du rapport
Job Talend J01_* staging	captures/talend/	Chapitre 6.3
Job Talend J02_Load_Dimensions	captures/talend/	Chapitre 6.4
Job Talend J03_Load_F_AVIS	captures/talend/	Chapitre 6.5
Job Talend J04_SCD2_Demo	captures/talend/	Chapitre 5.5
Vérification tables staging pgAdmin	captures/postgresql/	Chapitre 6.7
Vérification Data Mart pgAdmin	captures/postgresql/	Chapitre 6.7
Résultat SCD2 pgAdmin	captures/postgresql/	Chapitre 5.6
Résultats Analyses OLAP 1 à 10	captures/olap/	Chapitre 7
Dashboard Power BI Page 1	captures/powerbi/	Chapitre 8.4

Dashboard Power BI Page 2	captures/powerbi/	Chapitre 8.5
Dashboard Power BI Page 3	captures/powerbi/	Chapitre 8.6